

东华理工大学 2026 大数据生产实习

教师授课讲义 + 学生实操手册

VirtualBox + Ubuntu 22.04.x + JDK 8 + Hadoop 3.x
+ Hive + Flume + Sqoop + Kafka + Spark + Spring Boot 3/4 + ECharts

本教材的授课原则: 每一步先解释“为什么”，再给出“命令”，最后必须看到“结果”。命令复制即可执行，出现异常按“故障排查”章节定位。

版本冻结：2026-08-18 课堂版

0. 先读这一页：这门课到底要做什么

本教材严格围绕你提供的生产实习方案中的“数据科学与大数据技术方向”组织。原方案要求掌握 Linux、Hadoop、Flume、Sqoop、ECharts，覆盖数据采集、存储、计算、分析、可视化，并以“东软全域旅游客流调度分析平台”或“动漫推荐系统”等项目进行实践。

层级	学生最终要会什么	本教材对应组件
开发环境	Ubuntu、终端、SSH、Git、Maven	VirtualBox + Ubuntu 22.04
数据采集	把日志/CSV/模拟行为送进数据平台	Flume、Kafka、Java Producer
数据存储	在分布式文件系统里管理数据	HDFS
数据仓库	把原始数据整理成可分析的主题数据	Hive
离线计算	统计、清洗、聚合	MapReduce、Spark
服务层	把分析结果通过 HTTP 暴露	Spring Boot 3.x/4.x
可视化	做客流、订单、地区、时段看板	ECharts
工程化	代码、配置、日志、交付	Git + Maven + 文档




图 0-1 课堂最终项目的“大数据链路”

最终成果: 学生不是“会安装软件”就算完成，而是能够从 tourism_behavior.csv 出发，完成采集 -> HDFS -> Hive -> Spark/MapReduce -> Spring Boot API -> ECharts 大屏，并现场解释每层为什么存在。

1. 课堂统一版本：先把版本锁死

课堂环境最怕“老师一套版本、学生另一套版本”。因此教材采用一套可复制的版本组合。Apache Hadoop 3.3.6 是 Hadoop 3.3 分支发布版本；Spark 3.5.7 官方文档明确支持 Java 8/11/17，并说明 Java 8 低于 8u371 已不再推荐。Spring Boot 3.5.x 和 4.1.0 都要求 Java 17，因此 Java 大数据组件与 Spring Boot 采用“双 JDK”策略。

组件	课堂版本	运行 JDK	用途	本地准备文件
VirtualBox	7.1.x	Windows 主机	虚拟机	VirtualBox-7.1.x-Win.exe
Ubuntu	22.04.x LTS	-	开发 Linux	ubuntu-22.04.x-desktop-amd64.iso
JDK	8u482 / OpenJDK 8	8	Hadoop/Hive/Spark 课堂线	OpenJDK8/Temurin8 tar.gz
JDK	17 LTS	17	Spring Boot 3/4、Kafka 3.9.2	Temurin17 tar.gz
Hadoop	3.3.6	8	HDFS/YARN/MapReduce	hadoop-3.3.6.tar.gz
Hive	3.1.3	8	数仓、SQL	apache-hive-3.1.3-bin.tar.gz
Flume	1.11.0	8	日志采集	apache-flume-1.11.0-bin.tar.gz
Sqoop	1.4.7	8	MySQL<->Hadoop 迁移演示	sqoop-1.4.7.bin__hadoop-2.6.0.tar.gz

组件	课堂版本	运行 JDK	用途	本地准备文件
Kafka	3.9.2	17	消息队列/实时数据	kafka_2.13-3.9.2.tgz
Spark	3.5.7	8	批处理/SQL/实时思路	spark-3.5.7-bin-hadoop3.tgz
MySQL	8.0.x	17/8	业务数据源	MySQL Community Server 8.0.x
IDEA	Community/Ultimate	17	Java 编程	IntelliJ IDEA
Maven	3.9.x	17	Spring Boot 构建	apache-maven-3.9.x-bin.tar.gz

为什么需要双 JDK: Spring Boot 3.0+明确要求 Java 17，Spring Boot 4.1.0 也要求至少 Java 17；因此不能让学生误以为“全机器只能装 JDK8”。JDK8 与 JDK17 可以并存，课堂中用 JAVA_HOME 切换。

2. 本地“安装包仓库” - 老师课前一次准备好

建议老师在 Windows 上建立 D:\BigDataClass\software，把下列文件全部下载后复制到共享盘/U 盘，再发给学生。课堂机器不要依赖现场下载。

老师统一软件目录

```
D:\BigDataClass\software\
  01-VirtualBox\
  02-Ubuntu\
  03-JDK8\
  04-JDK17\
  05-Hadoop\
  06-Hive\
  07-Flume\
  08-Sqoop\
  09-Kafka\
  10-Spark\
  11-MySQL\
  12-Maven\
  13-IDEA\
  14-project-data\
```

软件	下载地址	说明
VirtualBox 7.1.x	https://www.virtualbox.org/wiki/Downloads	Oracle 官方下载页
Ubuntu 22.04 LTS	https://releases.ubuntu.com/22.04/	Ubuntu 官方发行版目录
Temurin JDK 8	https://adoptium.net/temurin/releases/?version=8	Eclipse Adoptium JDK 8
Temurin JDK 17	https://adoptium.net/temurin/releases/?version=17	Eclipse Adoptium JDK 17
Hadoop 3.3.6	https://hadoop.apache.org/release/3.3.6.html	Apache 官方发布页
Hive 3.1.3	https://archive.apache.org/dist/hive/hive-3.1.3/	Apache Archive
Flume 1.11.0	https://flume.apache.org/download.html	Apache 官方下载页
Sqoop 1.4.7	https://archive.apache.org/dist/sqoop/1.4.7/	Apache Archive (历史版本)
Kafka 3.9.2	https://kafka.apache.org/community/	Apache 官方下载页

软件	下载地址	说明
	downloads/	
Spark 3.5.7	https://spark.apache.org/downloads.html	Apache 官方下载页
MySQL 8.0	https://dev.mysql.com/downloads/mysql/8.0.html	Oracle 官方下载页
Maven 3.9.x	https://maven.apache.org/download.cgi	Apache 官方下载页
IntelliJ IDEA	https://www.jetbrains.com/idea/download/	JetBrains 官方下载页
Spring Initializr	https://start.spring.io/	Spring 官方项目生成器

版本来源核对: 本教材使用官方项目下载页作为“课堂母站”。Sqoop 1.4.7 已属于 Apache Archive 历史归档，官方归档页面也明确提示历史归档可能不再受支持；因此课堂只把 Sqoop 当作“迁移概念演示”，核心成果不依赖 Sqoop。

3. VirtualBox + Ubuntu 22.04.x：从开机到可上课

3.1 Windows 主机要求

项目	建议	课堂理由
CPU	Intel i5/i7 或 AMD Ryzen 5/7，支持虚拟化	学生会同时跑 Hadoop/Hive/Spark
内存	16 GB 最低，32 GB 推荐	4-8 GB 给虚拟机更舒服
磁盘	至少 100 GB 可用	软件包 + 虚拟磁盘 + 数据集
网络	桥接或 NAT 均可	本地共享安装包即可减少对网速依赖

3.2 创建 Ubuntu 虚拟机

在 VirtualBox -> 新建。名称 BigData-Ubuntu2204；类型 Linux；版本 Ubuntu (64-bit)。内存建议 8192 MB；CPU 建议 4；磁盘 60 GB、VDI、动态分配。网络第一块网卡选择 NAT。

VirtualBox 课堂动作清单


```
# 进入宿主机确认虚拟化已开启 (Windows PowerShell)
systeminfo
# 观察“虚拟化已在固件中启用”是否为“是”
# VirtualBox 创建完成后启动虚拟机
# 安装 Ubuntu 时用户名建议: bigdata
# 密码课堂统一，例如: Bigdata@123 (正式系统不要使用课堂密码)
```

重要: 所有学生的用户名统一成 bigdata，后面配置 SSH、HDFS 权限、路径时少掉大量“用户名不同导致路径不同”的问题。

3.3 Ubuntu 第一次开机

第一次开机必须执行

```
sudo apt update
sudo apt upgrade -y
sudo apt install -y vim wget curl unzip zip tar rsync net-tools openssh-server openssh-client git tree lsof telnet
netcat-openbsd
sudo systemctl enable ssh
sudo systemctl start ssh
systemctl status ssh --no-pager
ip a
hostname
whoami
df -h
free -h
```



```

Java 8 环境检查

$ java -version
openjdk version "1.8.0_482"

$ echo $JAVA_HOME
/opt/jdk8
    
```

图 3-1 终端命令的视觉形式：课堂强调“命令、结果、解释”三步

3.4 VirtualBox 共享文件夹：老师把软件给到学生

为了避免课堂反复下载，把 Windows 共享目录挂载到 Ubuntu。VirtualBox 菜单：设置 -> 共享文件夹 -> 增加。文件夹路径选择 D:\BigDataClass\software，名称填写 bigdata_software，勾选“自动挂载”“固定分配”。

共享文件夹验证

```

sudo apt install -y virtualbox-guest-utils virtualbox-guest-x11
sudo reboot
# 重启后查看共享目录
ls -lh /media/
# 如果自动挂载成功，常见路径类似 /media/sf_bigdata_software
ls -lh /media/sf_bigdata_software
    
```

备课强烈建议：完成 Ubuntu 基础安装、JDK8、Hadoop 单机伪分布式并成功启动后，立即在 VirtualBox 做一个“干净快照”：BigData-Base。学生后面装坏了可以快速恢复。

4. JDK 8 + JDK 17 双版本共存

4.1 安装目录统一

课堂命令

```
sudo mkdir -p /opt/jdk8 /opt/jdk17 /opt/soft /data /data/hadoop
sudo chown -R bigdata:bigdata /opt/jdk8 /opt/jdk17 /opt/soft /data
```

把老师准备好的 JDK 压缩包复制到 /opt/soft。例如：OpenJDK8U-jdk_x64_linux_hotspot_8u482b08.tar.gz、OpenJDK17U-jdk_x64_linux_hotspot_17.0.18_8.tar.gz。文件名以你实际下载的文件为准。

课堂命令

```
cd /opt/soft
tar -xzf OpenJDK8U-jdk_x64_linux_hotspot_8u482b08.tar.gz
mv jdk8u482-b08 /opt/jdk8
tar -xzf OpenJDK17U-jdk_x64_linux_hotspot_17.0.18_8.tar.gz
mv jdk-17.0.18_8 /opt/jdk17
ls -l /opt/jdk8/bin/java
ls -l /opt/jdk17/bin/java
```

4.2 写两个切换脚本

~/use-jdk8.sh

```
#!/bin/bash
# ~/use-jdk8.sh
export JAVA_HOME=/opt/jdk8
export PATH=$JAVA_HOME/bin:$PATH
java -version
javac -version
```

~/use-jdk17.sh

```
#!/bin/bash
# ~/use-jdk17.sh
export JAVA_HOME=/opt/jdk17
export PATH=$JAVA_HOME/bin:$PATH
java -version
javac -version
```

课堂命令

```
chmod +x ~/use-jdk8.sh ~/use-jdk17.sh
source ~/use-jdk8.sh
java -version
source ~/use-jdk17.sh
java -version
source ~/use-jdk8.sh
```

课堂规则: 进入 Hadoop/Hive/Spark 实验前先执行 `source ~/use-jdk8.sh`；进入 Spring Boot/Kafka 实验前执行 `source ~/use-jdk17.sh`。不要让学生死记环境变量。

5. Hadoop 3.3.6：从零部署伪分布式 HDFS/YARN

5.1 解压 Hadoop

课堂命令

```
source ~/use-jdk8.sh
cd /opt/soft
tar -xzf hadoop-3.3.6.tar.gz
mv hadoop-3.3.6 /opt/hadoop
echo $JAVA_HOME
/opt/jdk8
echo $HADOOP_HOME # 此时还没有值，下一步再配置
```

5.2 配置环境变量

课堂命令

```
vim ~/.bashrc
# 追加以下内容
export JAVA_HOME=/opt/jdk8
export HADOOP_HOME=/opt/hadoop
export HADOOP_CONF_DIR=$HADOOP_HOME/etc/hadoop
export PATH=$JAVA_HOME/bin:$HADOOP_HOME/bin:$HADOOP_HOME/sbin:$PATH
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
source ~/.bashrc
java -version
hadoop version
```

5.3 SSH 无密码登录 localhost

课堂命令

```
sudo systemctl status ssh --no-pager
ssh-keygen -t rsa -P "" -f ~/.ssh/id_rsa
cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
chmod 600 ~/.ssh/authorized_keys
ssh localhost
# 第一次连接输入 yes；如果成功，输入 exit 退出
exit
```

5.4 配置 core-site.xml

/opt/hadoop/etc/hadoop/core-site.xml

```
<?xml version="1.0" encoding="UTF-8"?>
<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://localhost:9000</value>
```

```
</property>
</configuration>
```

5.5 配置 hdfs-site.xml

/opt/hadoop/etc/hadoop/hdfs-site.xml

```
<?xml version="1.0" encoding="UTF-8"?>
<configuration>
  <property>
    <name>dfs.replication</name>
    <value>1</value>
  </property>
  <property>
    <name>dfs.namenode.name.dir</name>
    <value>file:/data/hadoop/name</value>
  </property>
  <property>
    <name>dfs.datanode.data.dir</name>
    <value>file:/data/hadoop/data</value>
  </property>
</configuration>
```

5.6 配置 mapred-site.xml

课堂命令

```
cd /opt/hadoop/etc/hadoop
cp mapred-site.xml.template mapred-site.xml
```

mapred-site.xml

```
<?xml version="1.0"?>
<configuration>
  <property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
  </property>
</configuration>
```

5.7 配置 yarn-site.xml

yarn-site.xml

```
<?xml version="1.0"?>
<configuration>
  <property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  </property>
  <property>
    <name>yarn.resourcemanager.hostname</name>
```

```
<value>localhost</value>
</property>
</configuration>
```

5.8 Hadoop 关键命令：格式化、启动、验证、停止

Hadoop 必做命令

```
mkdir -p /data/hadoop/name /data/hadoop/data
chmod -R 755 /data/hadoop
hdfs namenode -format
start-dfs.sh
start-yarn.sh
jps
hdfs dfs -ls /
hdfs dfsadmin -report
yarn node -list
stop-yarn.sh
stop-dfs.sh
```



A terminal window titled "HDFS 操作示例" (HDFS Operation Examples) showing the following commands and their outputs:

```
$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
$ jps
NameNode
DataNode
SecondaryNameNode
$ hdfs dfs -mkdir -p /bigdata/input
$ hdfs dfs -put tourism.csv /bigdata/input/
```

图 5-1 HDFS 实验操作示例

成功标准: jps 至少看到 NameNode、DataNode、SecondaryNameNode；启动 YARN 后再看到 ResourceManager、NodeManager。HDFS 能执行 hdfs dfs -ls / 即算第一阶段成功。

6. HDFS：先把“大数据黑话”讲明白




图 6-1 HDFS 的最小心智模型：NameNode 管目录和元数据，DataNode 真正存数据块

术语	白话解释	你可以怎么讲给学生
NameNode	管理 HDFS 的“文件目录和元数据”	像图书馆目录管理员，不负责搬每一本书
DataNode	真正保存数据块	像一个个书架
Block	文件切成的一小块数据	一本大书拆成多箱运输
Replication	副本数	同一份数据多存几份，机器坏了仍能读
HDFS	分布式文件系统	把多台机器的磁盘组织成一个“大文件系统”
YARN	资源调度框架	像学校机房的“资源管理员”，决定谁用 CPU/内存
MapReduce	经典批处理模型	先 Map 分发处理，再 Reduce 汇总
Hive	数据仓库层 + SQL	让数据工程师用类似 SQL 的方式分析 HDFS 数据
Spark	通用计算引擎	比传统 MapReduce 更适合复杂计算、SQL、迭代
Kafka	消息队列/事件流平台	像一个高速“传送带”，生产者往里放，消费者取走
Flume	日志采集工具	像一个专业“搬运工”，负责把日志搬到下一站
ETL	Extract Transform Load	抽取、转换、装载
ODS/DWD/DWS/ADS	数仓分层	原始层、清洗明细层、主题汇总层、应用指标层

6.1 HDFS 基础命令 1：目录

课堂命令

```
hdfs dfs -mkdir -p /bigdata/input
hdfs dfs -mkdir -p /bigdata/output
hdfs dfs -ls /
hdfs dfs -ls /bigdata
hdfs dfs -ls -R /bigdata
```

6.2 HDFS 基础命令 2：上传、下载、查看、删除

课堂命令

```
cp /media/sf_bigdata_software/14-project-data/tourism_behavior.csv ~/tourism_behavior.csv
hdfs dfs -put ~/tourism_behavior.csv /bigdata/input/
hdfs dfs -ls -h /bigdata/input
hdfs dfs -cat /bigdata/input/tourism_behavior.csv | head
hdfs dfs -du -h /bigdata/input
hdfs dfs -get /bigdata/input/tourism_behavior.csv ~/download_tourism.csv
hdfs dfs -rm /bigdata/input/tourism_behavior.csv
```

课堂动作: 让学生打开 HDFS Web UI（默认常用地址：<http://localhost:9870>），同时执行命令查看 /bigdata/input。用“命令行 + 页面”双视角理解 HDFS。

7. Java MapReduce：第一个真正的大数据程序

7.1 项目创建

课堂命令

```
source ~/use-jdk8.sh
mkdir -p ~/bigdata-lab/mapreduce-wordcount/src/main/java/com/example
cd ~/bigdata-lab/mapreduce-wordcount
vim pom.xml
```

mapreduce-wordcount/pom.xml

```
<project xmlns="http://maven.apache.org/POM/4.0.0">
  <modelVersion>4.0.0</modelVersion>
  <groupId>com.example</groupId>
  <artifactId>mapreduce-wordcount</artifactId>
  <version>1.0.0</version>
  <properties><maven.compiler.source>8</maven.compiler.source><maven.compiler.target>8</maven.compiler.target></properties>
  <dependencies>
    <dependency>
      <groupId>org.apache.hadoop</groupId><artifactId>hadoop-common</artifactId><version>3.3.6</version>
    </dependency>
    <dependency>
      <groupId>org.apache.hadoop</groupId><artifactId>hadoop-mapreduce-client-core</artifactId><version>3.3.6</version>
    </dependency>
  </dependencies>
</project>
```

WordCount.java

```
package com.example;

import java.io.IOException;
import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;

public class WordCount {
    public static class MyMapper extends Mapper<Object, Text, Text, IntWritable> {
        private final static IntWritable ONE = new IntWritable(1);
        private final Text KEY = new Text();
        public void map(Object key, Text value, Context context) throws IOException, InterruptedException {
            String[] words = value.toString().split("\\s+");
            for (String word : words) {
```

```

        if (!word.isEmpty()) { KEY.set(word); context.write(KEY, ONE); }
    }
}
}
public static class MyReducer extends Reducer<Text, IntWritable, Text, IntWritable> {
    private final IntWritable result = new IntWritable();
    public void reduce(Text key, Iterable<IntWritable> values, Context context) throws IOException,
    InterruptedException {
        int sum = 0; for (IntWritable v : values) sum += v.get(); result.set(sum); context.write(key, result);
    }
}
public static void main(String[] args) throws Exception {
    Configuration conf = new Configuration(); Job job = Job.getInstance(conf, "word count");
    job.setJarByClass(WordCount.class); job.setMapperClass(MyMapper.class); job.setReducerClass(MyReducer.class);
    job.setOutputKeyClass(Text.class); job.setOutputValueClass(IntWritable.class);
    FileInputFormat.addInputPath(job, new Path(args[0])); FileOutputFormat.setOutputPath(job, new Path(args[1]));
    System.exit(job.waitForCompletion(true) ? 0 : 1);
}
}

```

课堂命令

```

cd ~/bigdata-lab/mapreduce-wordcount
mvn clean package -DskipTests
hdfs dfs -mkdir -p /bigdata/wordcount/input
echo "hello hadoop hello bigdata" > ~/wc.txt
hdfs dfs -put -f ~/wc.txt /bigdata/wordcount/input/
hadoop jar target/mapreduce-wordcount-1.0.0.jar com.example.WordCount /bigdata/wordcount/input
/bigdata/wordcount/output
hdfs dfs -cat /bigdata/wordcount/output/part-r-00000

```

学生必须说出来: Mapper 是“逐条/逐块处理”，Reducer 是“按 key 汇总”。真正重要的不是背代码，而是理解“输入 -> Map -> Shuffle -> Reduce -> 输出”的过程。

8. Hive：把 HDFS 变成“会 SQL 的数据仓库”

Hive 的教学重点不是把学生训练成 Hive 管理员，而是让他们理解“文件数据 -> 表 -> SQL -> 统计指标”。使用 Hive 3.1.3 做课堂主线，老师可以在本地提前把安装包和 MySQL JDBC 驱动放入共享目录。

8.1 安装 Hive 3.1.3

课堂命令

```
source ~/use-jdk8.sh
cd /opt/soft
tar -xzf apache-hive-3.1.3-bin.tar.gz
mv apache-hive-3.1.3-bin /opt/hive
echo 'export HIVE_HOME=/opt/hive' >> ~/.bashrc
echo 'export PATH=$HIVE_HOME/bin:$PATH' >> ~/.bashrc
source ~/.bashrc
hive --version
```

8.2 先做“内置 Derby”最小实验

课堂命令

```
cd ~
mkdir -p hive-lab
cd hive-lab
hive
show databases;
create database tourism;
show databases;
use tourism;
create table hello(id int, name string);
insert into hello values(1,'南京'),(2,'苏州');
select * from hello;
quit;
```

为什么第一次不接 MySQL: 教学第一节先让学生跑通 Hive CLI，不要一开始就把学生淹没在 Metastore、JDBC 驱动和 MySQL 配置里。第二节再讲“元数据为什么要单独存”。

8.3 旅游数据表

课堂命令

```
hdfs dfs -mkdir -p /bigdata/tourism/ods
hdfs dfs -put -f ~/tourism_behavior.csv /bigdata/tourism/ods/
hive
```

Hive 建表 SQL


```
CREATE DATABASE IF NOT EXISTS tourism;
USE tourism;
```

```
CREATE EXTERNAL TABLE IF NOT EXISTS tourism_behavior (
  id BIGINT, event_time STRING, scenic STRING, province STRING,
  channel STRING, behavior STRING, paid STRING, amount DOUBLE,
  weather STRING, age INT
)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
STORED AS TEXTFILE
LOCATION '/bigdata/tourism/ods';
```

课堂命令

```
select count(*) from tourism_behavior;
select scenic, count(*) cnt from tourism_behavior group by scenic order by cnt desc;
select channel, count(*) cnt from tourism_behavior group by channel;
select province, sum(amount) revenue from tourism_behavior group by province order by revenue desc;
```

8.4 数仓分层：ODS/DWD/DWS/ADS



东华理工大学 2026 大数据生产实习 - 教师授课讲义

图 8-1 旅游项目的数据仓库分层

层	含义	旅游项目示例
ODS	原始数据层	原始游客行为 CSV
DWD	明细层	补齐字段、清理脏数据、标准化时间
DWS	主题汇总层	按景区/日期/渠道汇总
ADS	应用数据层	前端直接展示的 TOP 景区、客流趋势、收入排行

9. Flume + Kafka：理解“批处理”和“实时流”的区别




图 9-1 Kafka：Producer -> Topic -> Partition -> Consumer

9.1 Flume 是什么

Flume 是专门处理日志/事件采集的工具。最典型的讲法：Source 接收数据，Channel 临时承载，Sink 把数据送到下一站。可以把它讲成“搬家公司”：Source 是收货口，Channel 是仓库，Sink 是送货口。Apache Flume 官方把它定义为用于高效收集、聚合和移动大量日志数据的分布式可靠服务。

9.2 Flume 最小课堂案例：tail -F -> HDFS

课堂命令

```

source ~/use-jdk8.sh
cd /opt/soft
tar -xzf apache-flume-1.11.0-bin.tar.gz
mv apache-flume-1.11.0-bin /opt/flume
echo 'export FLUME_HOME=/opt/flume' >> ~/.bashrc
echo 'export PATH=$FLUME_HOME/bin:$PATH' >> ~/.bashrc
source ~/.bashrc
flume-ng version
    
```

flume-tourism.conf

```

agent1.sources = r1
agent1.channels = c1
agent1.sinks = k1

agent1.sources.r1.type = exec
agent1.sources.r1.command = tail -F /home/bigdata/tourism.log
agent1.sources.r1.channels = c1

agent1.channels.c1.type = memory
agent1.channels.c1.capacity = 1000
agent1.channels.c1.transactionCapacity = 100

agent1.sinks.k1.type = hdfs
agent1.sinks.k1.hdfs.path = hdfs://localhost:9000/bigdata/flume/%Y-%m-%d/%H
agent1.sinks.k1.hdfs.fileType = DataStream
agent1.sinks.k1.hdfs.writeFormat = Text
agent1.sinks.k1.channel = c1
    
```

课堂命令

```
mkdir -p ~/flume-lab
touch ~/tourism.log
flume-ng agent -n agent1 -c conf -f ~/flume-lab/flume-tourism.conf -Dflume.root.logger=INFO,console
# 新开另一个终端
echo "2026-08-18,夫子庙,view" >> ~/tourism.log
echo "2026-08-18,中山陵,order" >> ~/tourism.log
hdfs dfs -ls -R /bigdata/flume
```

9.3 Kafka 最小案例

Kafka 3.9.2 适合本课程作为 Java 应用侧的消息队列演示；需要注意，Kafka 4.x 服务端已移除 Java 8 支持，因此本教材为了兼顾 Java 8 Hadoop 线与现代 Java 服务线，把 Kafka 固定在 3.9.x，并在 Kafka 实验时切换 JDK17。

Kafka 3.9.x 单机启动

```
source ~/use-jdk17.sh
cd /opt/soft
tar -xzf kafka_2.13-3.9.2.tgz
mv kafka_2.13-3.9.2 /opt/kafka
cd /opt/kafka
bin/kafka-storage.sh random-uuid
# 把输出复制下来，假设为 KAFKA_CLUSTER_ID
export KAFKA_CLUSTER_ID="替换为上一步输出"
bin/kafka-storage.sh format --standalone -t $KAFKA_CLUSTER_ID -c config/server.properties
bin/kafka-server-start.sh config/server.properties
```

课堂命令

```
# 新终端，仍然用 JDK17
cd /opt/kafka
bin/kafka-topics.sh --create --topic tourism_behavior --bootstrap-server localhost:9092 --partitions 2 --
replication-factor 1
bin/kafka-topics.sh --list --bootstrap-server localhost:9092
bin/kafka-console-producer.sh --topic tourism_behavior --bootstrap-server localhost:9092
# 输入：1,夫子庙,view
# 再开一个终端
bin/kafka-console-consumer.sh --topic tourism_behavior --from-beginning --bootstrap-server localhost:9092
```

10. Sqoop：老师必须讲，但不要把它成果压在它身上

为什么这样处理：Apache Sqoop 1.4.7 已进入 Archive，且其 Hadoop 二进制包是为 Hadoop 2.6.0 构建的。因此在本教材里，Sqoop 定位为“理解传统批量迁移工具”的课程知识，不把最终项目成功与否绑定到 Sqoop。原实习方案把 Sqoop 列为目标工具，课堂仍保留完整概念和最小演示。

10.1 教学生理解 Sqoop

一句话：Sqoop 解决的是“关系数据库 ↔ Hadoop 生态”的批量数据搬运问题。典型场景：MySQL 订单表 -> HDFS/Hive；或者 HDFS 分析结果 -> MySQL。

课堂命令

```
cd /opt/soft
tar -xzf sqoop-1.4.7.bin__hadoop-2.6.0.tar.gz
mv sqoop-1.4.7.bin__hadoop-2.6.0 /opt/sqoop
echo 'export SQOOP_HOME=/opt/sqoop' >> ~/.bashrc
echo 'export PATH=$SQOOP_HOME/bin:$PATH' >> ~/.bashrc
source ~/.bashrc
sqoop version
```

Sqoop 示例命令

```
# 仅作课堂示例，需先把 mysql-connector-j*.jar 放到 /opt/sqoop/lib
sqoop list-databases \
  --connect jdbc:mysql://localhost:3306/ \
  --username root \
  --password 123456
```

替代方案：真实企业项目现在更常见的是 Spark/Flink + CDC/ETL 等方式。学生掌握“数据迁移”思想比死记 Sqoop 参数更重要。

11. Spark 3.5.7: 从 RDD 到 DataFrame, 再到 Java

Spark 官方 3.5.7 文档明确支持 Java 8/11/17, 并说明 Spark 使用 Hadoop 客户端库与 HDFS/YARN 集成。课堂建议先让学生用 shell 验证, 再写 Java。

11.1 安装与验证

课堂命令

```
source ~/use-jdk8.sh
cd /opt/soft
tar -xzf spark-3.5.7-bin-hadoop3.tgz
mv spark-3.5.7-bin-hadoop3 /opt/spark
echo 'export SPARK_HOME=/opt/spark' >> ~/.bashrc
echo 'export PATH=$SPARK_HOME/bin:$SPARK_HOME/sbin:$PATH' >> ~/.bashrc
source ~/.bashrc
spark-shell --version
pyspark --version
```

11.2 第一条 Spark SQL

课堂命令

```
spark-sql
SHOW DATABASES;
CREATE DATABASE IF NOT EXISTS tourism;
USE tourism;
SHOW TABLES;
exit;
```

11.3 Java DataFrame 项目

TourismAnalysis.java

```
package com.example;

import org.apache.spark.sql.Dataset;
import org.apache.spark.sql.Row;
import org.apache.spark.sql.Session;
import static org.apache.spark.sql.functions.*;

public class TourismAnalysis {
    public static void main(String[] args) {
        Session spark = Session.builder()
            .appName("TourismAnalysis")
            .master("local[*]")
            .getOrCreate();

        Dataset<Row> df = spark.read()
            .option("header", "true")
```

```

.option("inferSchema", "true")
.csv("/home/bigdata/tourism_behavior.csv");

df.groupBy("scenic")
  .agg(count(lit(1)).alias("visits"))
  .orderBy(desc("visits"))
  .show(20, false);

spark.stop();
}
}

```

教学重点: Spark 不是“另一个 Hadoop”。Hadoop 更像“存储 + 资源 + 经典批处理生态”，Spark 更像“计算引擎”。两者可以一起工作：Spark 读取 HDFS 数据、跑在 YARN 上。

12. Spring Boot 3.x/4.x：把大数据结果变成 Java 服务




图 12-1 Spring Boot 只负责服务层：把分析结果提供给前端或其他系统

这里选择 Spring Boot 3.x/4.x 的目的，不是重新讲一遍 Spring，而是告诉学生：大数据分析不是终点。企业最终要把“指标”服务化，让 Web/H5/大屏能够访问。

版本关系: Spring Boot 3.5.x 与 4.1.0 均要求至少 Java 17，因此此章必须先执行 `source ~/use-jdk17.sh`。Hadoop/Hive/Spark 课堂实验结束后再切回 JDK8。

12.1 创建项目

课堂命令

```
source ~/use-jdk17.sh
java -version
mkdir -p ~/tourism-api
cd ~/tourism-api
```

推荐老师用 <https://start.spring.io> 生成项目；依赖选择 Spring Web、Validation。课堂先做一个固定数据接口，再改成读取 MySQL/文件里的分析结果。

Spring Boot Controller

```
package com.example.tourism;

import org.springframework.web.bind.annotation.GetMapping;
import org.springframework.web.bind.annotation.RequestMapping;
import org.springframework.web.bind.annotation.RestController;
import java.util.List;
import java.util.Map;

@RestController
@RequestMapping("/api/tourism")
public class TourismController {
    @GetMapping("/top-scenic")
    public List<Map<String, Object>> topScenic() {
        return List.of(
            Map.of("name", "夫子庙", "value", 3250),
            Map.of("name", "中山陵", "value", 2980),
            Map.of("name", "玄武湖", "value", 2650)
        );
    }
}
```

课堂命令

```
./mvnw spring-boot:run  
# 或者  
./mvnw clean package  
java -jar target/tourism-api-0.0.1-SNAPSHOT.jar  
# 新终端测试  
curl http://localhost:8080/api/tourism/top-scenic
```

学生成果: 浏览器或 curl 能拿到 JSON，就说明“Java 服务层”打通。下一步只是把 Map.of(...) 换成 MySQL 查询或 Hive/Spark 结果。

13. ECharts：让数据真正“看得懂”

13.1 最小页面

ECharts + Spring Boot

```
<!DOCTYPE html>
<html lang="zh-CN">
<head>
  <meta charset="UTF-8">
  <title>旅游客流大屏</title>
  <script src="https://cdn.jsdelivr.net/npm/echarts/dist/echarts.min.js"></script>
</head>
<body>
<div id="main" style="width: 100%; height: 500px;"></div>
<script>
const chart = echarts.init(document.getElementById('main'));
fetch('/api/tourism/top-scenic')
  .then(r => r.json())
  .then(data => {
    chart.setOption({
      title: { text: '热门景区客流排行' },
      xAxis: { type: 'category', data: data.map(x => x.name) },
      yAxis: { type: 'value' },
      series: [{ type: 'bar', data: data.map(x => x.value) }]
    });
  });
</script>
</body>
</html>
```

13.2 最终大屏指标建议

区域	指标	数据来源	可视化
核心 KPI	今日客流、订单数、收入	ADS	数字卡片
趋势	小时客流曲线	DWS	折线图
景区排行	TOP10 景区	DWS	柱状图
来源地	省份客流	DWS	地图/柱状图
渠道	APP/Web/微信	DWS	饼图/环形图
天气影响	天气 vs 客流	DWD/DWS	散点/折线

14. 综合项目：东华理工“旅游客流调度分析平台”




图 14-1 两周十天教学节奏

14.1 业务故事

景区每天产生大量游客行为数据。管理者希望看到：哪一个景区人最多、什么时间段客流最高、游客来自哪里、哪个渠道贡献订单、天气变化是否影响客流。学生以真实企业项目的方式完成从采集到看板的完整链路。

14.2 项目结构

模块	输入	处理	输出
数据准备	tourism_behavior.csv	格式校验、去重	clean.csv
采集	日志/CSV	Flume / Java Producer	HDFS/Kafka
数仓	ODS	Hive SQL 清洗	DWD
计算	DWD	Spark/MapReduce	DWS/ADS
服务	ADS	Spring Boot REST	JSON API
前端	JSON API	ECharts	可视化大屏

14.3 核心 SQL

核心分析 SQL

```
-- 1. 景区客流排行
SELECT scenic, COUNT(*) AS visits
FROM tourism_behavior
GROUP BY scenic
ORDER BY visits DESC;

-- 2. 每日订单收入
SELECT SUBSTR(event_time,1,10) AS day,
       COUNT(*) AS order_cnt,
       SUM(amount) AS revenue
FROM tourism_behavior
WHERE behavior='order' AND paid='Y'
GROUP BY SUBSTR(event_time,1,10)
ORDER BY day;

-- 3. 省份游客来源
SELECT province, COUNT(*) AS visitors
FROM tourism_behavior
GROUP BY province
ORDER BY visitors DESC;
```

14.4 个人任务差异化

岗位	基础任务	进阶任务	验收
组长/项目经理	任务拆分、Git	燃尽图/版本管理	项目进度清晰
数据工程	HDFS+Hive	分区/性能分析	SQL 结果正确
Java 后端	Spring Boot API	缓存/分页	接口可访问
前端	ECharts	交互筛选	大屏完整
算法/分析	Spark/统计	客流预测思路	分析报告
测试/文档	测试数据、文档	自动化测试	交付包完整

15. 老师课前数据包：直接给学生

本教材已经配套生成一份可独立使用的旅游客流模拟数据。数据不是“随机垃圾”，而是按照课堂指标设计：景区、来源省份、渠道、行为、是否支付、金额、天气、年龄等字段。

文件	行数	字段	用途
tourism_sample_500.csv	500	10 个字段	第一节手工观察/上传/建表
tourism_behavior.csv	12000	10 个字段	最终综合项目
tourism_schema.sql	需课堂创建	DDL	建库建表
project_readme.txt	-	步骤	课堂操作顺序

id	event_time	scenic	province	channel	behavior	paid	amount	weather	age
1	2026-07-01 13:13:00	中山陵	广东	wechat	favorite	N	0	大雨	68
2	2026-07-02 15:15:00	栖霞山	上海	app	search	N	0	晴	62
3	2026-07-03 12:48:00	南京博物院	浙江	web	order	Y	598.37	大雨	47
4	2026-07-04 22:00:00	总统府	湖北	web	view	N	0	多云	19
5	2026-07-05 11:14:00	玄武湖	湖北	miniapp	order	N	0	阴	51
6	2026-07-06 19:54:00	夫子庙	浙江	miniapp	order	Y	113.4	多云	62
7	2026-07-07 22:40:00	总统府	湖北	app	search	N	0	阴	22

数据版权/来源: 本教材中的旅游行为数据为课堂模拟数据，不来自东华理工或任何真实游客数据库，仅用于教学。

16. 两周 10 天：老师照着这个节奏上课

天	上午	下午	当天成果
Day1	VirtualBox/Ubuntu/Linux/JDK	Maven/Git/SSH/环境验证	每人一台可运行 Ubuntu + 双 JDK
Day2	Hadoop/HDFS 概念与部署	HDFS 命令 + MapReduce	WordCount 成功
Day3	Hive 安装/表/SQL	ODS/DWD/DWS/ADS	旅游数据 SQL 统计
Day4	Flume 架构/实验	Kafka Topic/Producer/Consumer	日志流能被消费
Day5	Spark 原理/SQL	Java Spark DataFrame	Spark 输出 Top 景区
Day6	项目需求/数据模型	分组/Git/数据库设计	需求说明书 + ER 图
Day7	HDFS/Hive 项目开发	Spark/MapReduce 指标开发	核心 ADS 指标
Day8	Spring Boot API	MySQL/结果服务化	REST API 可调用
Day9	ECharts	大屏联调/测试	可视化大屏
Day10	项目打磨	答辩/演示/复盘	完整交付包 + 现场答辩

每日固定套路: 30% 原理讲解 + 50% 跟做实操 + 20% 独立任务。每天下课前至少留下一个“可验收成果”，不要把所有成果拖到最后一天。

17. 大数据课堂命令速查表

类别	命令	作用
Linux	pwd	当前目录
Linux	ls -lh	列出文件
Linux	cd /opt	切换目录
Linux	cp -r A B	复制目录
Linux	mv A B	移动/重命名
Linux	rm -rf A	删除目录
Linux	grep "xxx" file	搜索文本
Linux	tail -f file	实时追踪日志
Linux	ps -ef grep java	查进程
Linux	jps	查 Java 进程
Linux	ss -lntp	查监听端口
HDFS	hdfs dfs -ls /	查看 HDFS
HDFS	hdfs dfs -mkdir -p /a/b	建目录
HDFS	hdfs dfs -put local /a	上传
HDFS	hdfs dfs -get /a/file .	下载
HDFS	hdfs dfs -cat /a/file	查看
HDFS	hdfs dfs -rm -r /a	删除
YARN	yarn application -list	应用列表
Hive	hive	进入 CLI
Hive	show databases;	数据库列表
Hive	show tables;	表列表
Hive	desc table;	表结构
Spark	spark-shell --version	版本
Spark	spark-sql	SQL CLI
Kafka	kafka-topics.sh --list ...	主题列表
Kafka	kafka-console-producer.sh ...	生产消息
Kafka	kafka-console-consumer.sh ...	消费消息
Maven	mvn clean package	打包
Spring	./mvnw spring-boot:run	运行

18. 课堂故障排查：老师最容易遇到的 40 个问题

现象	原因	处理
java: command not found	JAVA_HOME/PATH 未生效	source ~/.bashrc; java -version
Hadoop Error: JAVA_HOME is not set	Hadoop-env 没拿到 JDK8	检查 etc/hadoop/hadoop-env.sh
ssh localhost refused	SSH 服务未启动	sudo systemctl start ssh
Permission denied publickey	authorized_keys 权限不对	chmod 600 ~/.ssh/authorized_keys
NameNode already running	旧进程没停	jps 后 kill 对应 PID
Safe mode	HDFS 处于安全模式	hdfs dfsadmin -safemode leave
Output directory already exists	MapReduce 输出目录不能覆盖	hdfs dfs -rm -r /path/output
Hive command not found	HIVE_HOME 未配置	source ~/.bashrc
Hive metastore error	元数据库配置问题	先用 Derby 完成入门实验，再接 MySQL
ClassNotFoundException MySQL	JDBC 驱动缺失	把 mysql-connector-j 放入 Hive/lib 或项目依赖
Spark Java version error	Java 版本不匹配	Spark 章节切回 JDK8
Spring Boot 编译失败	还在用 JDK8	source ~/use-jdk17.sh
Kafka 启动失败	JDK 不足	Kafka 3.9.x 实验使用 JDK17
Port 8080 occupied	8080 被占用	ss -lntp grep 8080
Port 9870 cannot open	浏览器/防火墙/服务未启动	jps + curl localhost:9870
HDFS 无权限	当前用户不匹配	hdfs dfs -chmod /chown 临时实验
文件上传找不到	本地路径错误	pwd + ls -lh
CSV 中文乱码	编码不同	优先 UTF-8/UTF-8-SIG
Hive 一行全部进一列	分隔符错	检查 FIELDS TERMINATED BY
数值无法求和	字段读成 string	Hive cast/建表类型
Spark CSV 读不到	文件路径错	先 ls -lh 本地文件
Spark 结果空	列名/条件错误	df.printSchema(); df.show()
Kafka consumer 收不到	Topic/地址/服务错误	topic 列表 + server 日志
Flume 不产生文件	配置/权限/Source 无数据	前台启动看日志
Git push 失败	远程地址/账号问题	git remote -v
Maven 下载过慢	课堂网络问题	提前将依赖缓存或使用学校镜像
VirtualBox 无法启动 64 位	Windows 虚拟化未开启	BIOS/Hyper-V 排查
Ubuntu 黑屏	显存/3D 设置问题	关闭 3D 加速或提高显存
磁盘爆满	Hadoop 日志/虚拟磁盘	df -h + du -sh
内存不足	虚拟机分配太小	8GB/4CPU 起步
HDFS 数据块不存在	DataNode 未启动	jps + hdfs dfsadmin -report
YARN 无 NodeManager	服务启动失败	查看 logs/yarn-*.log
MapReduce 一直卡	YARN/资源不足	yarn node -list + 日志
Hive 表存在但查不到	LOCATION/路径错误	hdfs dfs -ls 对应目录
Spring Boot API 404	RequestMapping 不一致	查看控制器路径
ECharts 不显示	JS/接口错误	浏览器 F12 Network/Console
跨域	前后端不同端口	开发期配置 CORS
时间统计不正确	时区/字符串格式	统一 event_time 字段
Git 冲突	多人改同一文件	git pull --rebase 后人工解决
学生环境全坏	现场配置不可逆	恢复 BigData-Base 快照

19. 最终验收：成果必须“看得见”

成果物	最低标准	演示动作
环境报告	java -version / hadoop version / spark-shell --version	现场执行命令
HDFS 实验	能上传、查看、下载数据	展示 /bigdata/tourism
MapReduce	WordCount 或自定义统计成功	显示 part-r-00000
Hive	至少 3 条业务 SQL	现场跑 TOP 景区/省份/收入
Kafka	Topic + Producer + Consumer	现场发一条消息并消费
Spark	Java 程序输出统计结果	现场 spark-submit 或本地运行
Spring Boot	REST API 返回 JSON	浏览器/curl 调用
ECharts	至少 4 个图表	大屏演示
项目文档	需求、设计、部署、测试、答辩 PPT	提交完整项目包
Git	提交记录清晰	展示 commit history

19.1 最终演示顺序（建议老师强制）

课堂命令

1. 介绍业务：旅游客流为什么需要大数据
2. 展示 tourism_behavior.csv
3. 展示 HDFS 原始数据
4. 展示 Hive SQL 统计结果
5. 展示 Spark/MapReduce 处理过程
6. 启动 Spring Boot
7. 浏览器打开 ECharts 大屏
8. 修改一条数据/重新跑分析，说明链路可重复
9. 解释 Flume/Kafka 为什么存在
10. 回答答辩问题

项目不是“拼界面”：答辩时必须能说清楚：为什么用 HDFS、为什么用 Hive、为什么用 Spark、为什么 Kafka 与 Flume 不一样、为什么 Spring Boot 不能直接替代大数据平台。

20. 答辩题库：老师直接拿来问

问题	标准回答
HDFS 和普通 Linux 文件系统有什么区别？	HDFS 面向大文件和分布式存储，把文件切成 Block 存到多个 DataNode。
NameNode 存什么？	目录和元数据，不直接保存用户文件正文。
YARN 是干什么的？	负责集群资源管理和任务调度。
MapReduce 为什么有 Map 和 Reduce？	Map 做并行处理，Shuffle 按 key 聚合，Reduce 做汇总。
Hive 是数据库吗？	更准确说是构建在 Hadoop 生态上的数据仓库工具和 SQL 层。
Hive 和 MySQL 区别？	MySQL 是 OLTP 关系数据库；Hive 更偏大规模离线分析。
Spark 和 MapReduce 关系？	都是计算框架；Spark 更通用、适合迭代和 SQL，也可运行在 YARN 上。
Flume 和 Kafka 什么关系？	Flume 偏采集，Kafka 偏消息/事件流存储与分发；可以组合。
为什么还要 Kafka？	需要解耦生产者 and 消费者，并支持多消费者、缓冲和流式处理。
为什么需要 Spring Boot？	把数据分析结果服务化，让前端、业务系统通过 REST 使用。
什么是 ETL？	Extract、Transform、Load。
什么是分区？	根据日期等字段物理/逻辑组织数据，减少扫描范围。
ODS/DWD/DWS/ADS？	原始、明细、主题汇总、应用指标。

问题	标准回答
什么是大数据？	不仅是“数据量大”，还涉及数据产生速度、类型、处理复杂度等问题。
本项目最核心的成果是什么？	端到端数据链路可运行且每个组件作用说得清楚。

附录 A：官方资料与下载地址（备课收藏）

组件	官方/归档地址	用途
VirtualBox 7.1.x	https://www.virtualbox.org/wiki/Downloads	Oracle 官方下载页
Ubuntu 22.04 LTS	https://releases.ubuntu.com/22.04/	Ubuntu 官方发行版目录
Temurin JDK 8	https://adoptium.net/temurin/releases/?version=8	Eclipse Adoptium JDK 8
Temurin JDK 17	https://adoptium.net/temurin/releases/?version=17	Eclipse Adoptium JDK 17
Hadoop 3.3.6	https://hadoop.apache.org/release/3.3.6.html	Apache 官方发布页
Hive 3.1.3	https://archive.apache.org/dist/hive/hive-3.1.3/	Apache Archive
Flume 1.11.0	https://flume.apache.org/download.html	Apache 官方下载页
Sqoop 1.4.7	https://archive.apache.org/dist/sqoop/1.4.7/	Apache Archive（历史版本）
Kafka 3.9.2	https://kafka.apache.org/community/downloads/	Apache 官方下载页
Spark 3.5.7	https://spark.apache.org/downloads.html	Apache 官方下载页
MySQL 8.0	https://dev.mysql.com/downloads/mysql/8.0.html	Oracle 官方下载页
Maven 3.9.x	https://maven.apache.org/download.cgi	Apache 官方下载页
IntelliJ IDEA	https://www.jetbrains.com/idea/download/	JetBrains 官方下载页
Spring Initializr	https://start.spring.io/	Spring 官方项目生成器

附录 B：版本依据

Hadoop 3.3.6：Apache 官方发布页。Spark 3.5.7：官方文档明确支持 Java 8/11/17，并支持 Hadoop 集成。Flume 1.11.0：官方发布页说明该版本稳定且生产可用。Kafka：官方当前下载页列出 3.9.2；Kafka 4.0 兼容性文档明确说明 Java 8 已移除，因此课堂选 3.9.x 并配 JDK17。Spring Boot 3.5.x/4.1.0：Spring 官方系统要求均至少 Java 17。

本教材所有具体版本号均以 2026-08-18 网络核对结果为准。Apache Archive 中的历史组件（如 Sqoop、Hive 3.1.3）用于课堂复现，不意味着它们是生产环境最佳选择。

附录 C：老师课前检查清单

- ☐ 每台 Windows 电脑已安装 VirtualBox
- ☐ Ubuntu 22.04.x ISO 已统一
- ☐ BigData-Base 虚拟机模板已准备
- ☐ JDK8/JDK17 安装包已放到共享盘
- ☐ Hadoop/Hive/Flume/Sqoop/Kafka/Spark 安装包已放到共享盘
- ☐ MySQL/Maven/IDEA 安装包已放到共享盘
- ☐ tourism_sample_500.csv 已发给学生
- ☐ tourism_behavior.csv 已发给学生
- ☐ 老师机器 HDFS/Hive/Spark 全部跑通

- ☐ Spring Boot 3.x/4.x 项目能用 JDK17 启动
- ☐ ECharts 页面能访问 API
- ☐ 最终项目演示顺序已彩排一遍
- ☐ 准备一份 BigData-Base 快照用于现场救援

最后提醒: 这份讲义的目的不是让学生背组件，而是让学生形成一条稳定的工程链：数据从哪里来 -> 存在哪里 -> 怎么算 -> 怎么服务 -> 怎么展示 -> 怎么交付。